

Taller: Métricas, datos y calibración

Alejandro Cuevas Estupiñan // Miguel Alberto Romero Virguez

27 de septiembre de 2025

Resumen

En este trabajo se aborda el problema de la calibración de sensores de bajo costo, utilizados para medir la concentración de material particulado fino (PM2.5). A partir de datos de referencia, se plantea el cálculo de distancias entre conjuntos de mediciones, la construcción de un modelo de calibración basado en mínimos cuadrados y el análisis de la validez y alcance de dicho modelo. El objetivo es comprender cómo la elección de métricas y estrategias de ajuste impacta en la precisión de las predicciones.

1. Introducción

La proliferación de sensores de bajo costo ha abierto la posibilidad de monitorear fenómenos ambientales en tiempo real y a gran escala. Sin embargo, estos dispositivos no siempre garantizan la misma calidad de medición que las estaciones de referencia, lo que genera la necesidad de aplicar procesos de calibración. En este documento se presenta un estudio en el que se comparan las mediciones de sensores de bajo costo con datos de referencia para determinar su error, calibrarlos y evaluar su capacidad de predicción.

2. El problema

El problema central radica en determinar con precisión el error asociado a las mediciones realizadas por un sensor de bajo costo y establecer un procedimiento de calibración que permita corregir dichas desviaciones. El propósito

de este proceso es transformar los datos crudos del sensor en lecturas más confiables y comparables con las obtenidas por una estación de referencia, garantizando así su utilidad en aplicaciones de monitoreo ambiental y análisis científico.

2.1. Objetivos específicos

- Determinar la discrepancia entre las mediciones del sensor de bajo costo y las de referencia.
- Establecer una métrica adecuada que permita medir dicha discrepancia.
- Proponer un procedimiento de calibración que mejore la precisión del sensor.
- Evaluar la capacidad predictiva del modelo de calibración.

3. Estrategia para calcular la distancia

La comparación entre los datos del sensor y los de referencia requiere una métrica que capture las diferencias. En este caso, se emplea la **distancia euclídea** entre las mediciones:

$$D(D_i, \hat{D}_i) = \sqrt{\sum_i (D_i - \hat{D}_i)^2}$$

donde D_i representa los datos de referencia y $\hat{D}_i$ las mediciones del sensor.

Dado que los conjuntos de datos no siempre están tomados en los mismos instantes de tiempo, se utilizaron **promedios móviles** como estrategia de emparejamiento, con distintas ventanas temporales.

3.1. Promedios móviles

Con esta estrategia se buscó reducir las fluctuaciones locales y hacer comparables las tendencias de ambas series. Para ello se evaluaron distintos ta-

maños de ventana con un cierto paso de tiempo, con el fin de identificar aquel que lograra el mejor equilibrio entre precisión en la estimación y esfuerzo computacional.




Figura 1: Datos de referencia frente a los datos del sensor sin calibrar suavizados.

La figura muestra una comparación de los datos suavizados de la estación de referencia (AMB) y el sensor de bajo costo (IoT). Se puede apreciar el comportamiento del promedio móvil para ambas series de tiempo, lo que facilita la visualización de la tendencia general de los datos. Esto ayuda a comprender cómo la técnica del promedio móvil reduce la variabilidad, haciendo que la relación entre las dos estaciones sea más evidente.

4. Estrategia para calibrar las mediciones

La construcción de un modelo de calibración que relacione las mediciones de un sensor de bajo costo con las de una estación de referencia resulta indispensable, ya que estos dispositivos suelen presentar errores sistemáticos y aleatorios que afectan la confiabilidad de sus registros. Dicho modelo permite identificar y corregir las desviaciones observadas, transformando los datos crudos del sensor en estimaciones más cercanas a la realidad. De esta manera, se garantiza que las mediciones obtenidas sean útiles y comparables, facilitando tanto el análisis posterior como la integración del sensor en aplicaciones prácticas, siempre dentro del rango de validez definido para la calibración.

4.1. Valores de promedio móvil para diferentes ventanas




Figura 2: Sensor vs referencia 12h




Figura 3: Sensor vs referencia 24h




Figura 4: Sensor vs referencia 48h

El uso de promedios móviles permitió reducir la variabilidad local de los datos y mejorar la comparabilidad entre el sensor IoT y la estación de referencia. Con una ventana de 12 horas, se logró suavizar parcialmente las fluctuaciones, aunque aún se conservó un nivel considerable de ruido, especialmente en periodos de alta variabilidad.

Al ampliar la ventana a 24 horas, la señal se estabilizó notablemente, lo que facilitó la identificación de tendencias generales y una mejor correspondencia entre ambas series. Sin embargo, esta elección implicó la pérdida de algunos detalles en la dinámica diaria, ya que el suavizado comenzó a diluir las variaciones más rápidas.

Con ventanas de 48 horas, el efecto de suavizado se hizo mucho más evidente: las series mostraron una alta coincidencia en la tendencia global, pero a costa de eliminar prácticamente las variaciones de corto plazo. Esto generó una representación más estable de las concentraciones promedio, aunque menos sensible a cambios puntuales en la calidad del aire.

4.2. Resultados

4.2.1. Ajuste lineal

La estrategia inicial consiste en graficar los pares de puntos $(\hat{f}(\xi_j), f(\xi_j))$ y ajustar un modelo lineal mediante mínimos cuadrados:

$$f(\xi_j) = \alpha \hat{f}(\xi_j)$$

Los resultados mostraron que, en la mayor parte del intervalo de valores registrados, la recta de ajuste logró mantener un error dentro de los márgenes aceptables. La superposición de la curva de referencia y la predicción del modelo evidenció una buena correspondencia, lo que confirma la validez del ajuste en el rango considerado.





Figura 5: Gráfica de dispersión con la recta de ajuste lineal superpuesta

La gráfica evidencia una relación lineal consistente entre las mediciones del sensor de bajo costo y los valores de referencia, aunque con una pendiente de aproximadamente 0,8031. Este resultado indica que el sensor tiende a subestimar las concentraciones reales de material particulado un 20 por ciento. Aun así, la fuerte correlación observada confirma que, tras aplicar el ajuste lineal, es posible corregir de manera sistemática esta desviación y mejorar la confiabilidad de los datos obtenidos.


4.2.2. Validez del modelo

Para comprobar la capacidad predictiva del modelo, el conjunto de datos fue dividido en dos mitades: la primera se empleó en la construcción del

ajuste y la segunda se utilizó como validación independiente. La comparación mostró que el modelo mantuvo un nivel de error reducido al predecir las mediciones posteriores, lo que demuestra que es posible realizar una calibración efectiva sin necesidad de utilizar la totalidad de los datos disponibles. Esto evidencia que, incluso con un subconjunto limitado de información, el modelo conserva un buen desempeño y puede aplicarse con éxito en escenarios prácticos de monitoreo.



Tanto en esta primera figura de la validación del modelo, como en la segunda mitad de este, respecto a los datos se evidenció una correspondencia adecuada entre las predicciones y las mediciones reales dentro de un rango de tolerancia del 10 por ciento.



En particular, se identificó que el sensor calibrado mantiene su validez en el intervalo de 7.14 a 37.00 $\mu\text{g}/\text{m}^3$. El modelo de calibración lineal para el sensor de IoT es moderadamente efectivo, pero muestra debilidades significativas a bajas concentraciones de PM2.5. Aunque logra que el sensor siga la tendencia general del equipo de referencia, no es lo suficientemente preciso para ser considerado confiable en todos los rangos de medición, ya que solo el 62.2 por ciento de las mediciones de prueba caen dentro de la tolerancia aceptable del ± 10 por ciento.

5. Discusión

El proceso de calibración mostró una marcada dependencia de la calidad y cantidad de datos disponibles, así como de la selección del ancho de ventana en los promedios móviles y de la tolerancia definida para el error. Los resultados evidenciaron que la elección de estos parámetros condiciona directamente la precisión del modelo, lo que resalta la necesidad de un ajuste cuidadoso en cada aplicación concreta.

Asimismo, se observó que el modelo lineal utilizado, aunque no siempre logra capturar toda la complejidad de las mediciones, constituye un punto de partida sólido para evaluar la factibilidad de la calibración. Su desempeño demostró que, bajo ciertas condiciones, puede ofrecer predicciones suficien-

temente precisas para el monitoreo ambiental, aunque en escenarios más exigentes sería necesario explorar modelos más sofisticados que contemplen relaciones no lineales o efectos adicionales.

6. Conclusiones

El análisis realizado permitió evidenciar la utilidad del cálculo de distancias como herramienta para cuantificar la discrepancia entre las mediciones de los sensores de bajo costo y los datos de referencia. El uso de promedios móviles facilitó la comparación de ambas series, mostrando que la elección del tamaño de la ventana influye significativamente en la estimación del error y en la estabilidad de los resultados, lo que resalta la importancia de un ajuste adecuado de este parámetro.

La calibración mediante un modelo lineal ajustado por mínimos cuadrados demostró ser efectiva para corregir las desviaciones sistemáticas de los sensores. El valor de la pendiente obtenido ($\alpha \approx 0,8031$) reflejó la tendencia del dispositivo a subestimar las concentraciones reales de material particulado, lo cual pudo ser compensado a través del factor de corrección derivado del modelo. Este ajuste mejoró sustancialmente la coherencia entre las series, incrementando la confiabilidad de los datos para su uso en análisis posteriores.

La validación del modelo en la segunda mitad de los datos mostró que, bajo una tolerancia del 10 por ciento, el sensor calibrado es confiable en un rango de concentraciones entre 7.14 y 37.00 $\mu\text{g}/\text{m}^3$, con un 34 por ciento de los registros dentro de los márgenes de error aceptables. Este resultado evidencia que, si bien el modelo lineal no captura toda la complejidad del fenómeno, sí constituye una aproximación sólida que permite predecir con suficiente precisión dentro del rango de validez identificado.

Finalmente, el estudio demostró que los sensores de bajo costo pueden constituir una alternativa viable para el monitoreo ambiental siempre que se apliquen procedimientos de calibración adecuados. Aunque presentan limitaciones en escenarios de alta variabilidad o en valores extremos de concentración, la metodología implementada ofrece un marco replicable y escalable que contribuye a integrar este tipo de dispositivos en redes de medición confiables.